

Preprocessing dataset e analisi performance modelli su dataset pulito

Andrea Spagnolo 879254

Introduzione al problema.....	1
Provenienza dataset.....	2
Analisi esplorativa.....	3
Statistiche descrittive.....	3
Distribuzione dei dati.....	5
Analisi rispetto al target.....	9
Analisi di correlazione.....	13
Principal Component Analysis.....	14
Risultati principali.....	15
Modelli applicati.....	16
Alberi di decisione.....	17
Support Vector Machines.....	24
Reti neurali.....	29
Confronto risultati.....	34
Conclusioni.....	36

Introduzione al problema

Il dataset utilizzato in questo progetto, disponibile su Kaggle, contiene informazioni cliniche essenziali relative a pazienti con potenziale rischio di insufficienza cardiaca.

L'insufficienza cardiaca rappresenta la causa principale di mortalità a livello mondiale, richiedendo approcci efficaci per la diagnosi precoce e la prevenzione.

Per quanto riguarda le morti derivanti da problemi cardiovascolari, quattro su cinque di queste sono dovute ad attacchi di cuore o ictus, e un terzo di queste morti avviene prematuramente in persone di età inferiore a 70 anni. Identificare tempestivamente i pazienti a rischio è fondamentale per ridurre complicazioni e costi sanitari associati. In questo contesto, l'apprendimento automatico (machine learning) si presenta come uno strumento promettente per supportare i professionisti sanitari nell'individuare pattern e relazioni complesse tra le variabili cliniche che possono non essere immediatamente evidenti con le tecniche tradizionali.

Le feature a disposizione sono 11, ovvero:

1. **Age:** età in anni del paziente
2. **Sex:** sesso del paziente, nei valori M o F

3. **ChestPainType**: tipologia di dolore al petto
 - a. *TA*: Typical Angina, dolore toracico classico causato da ischemia cardiaca
 - b. *ATA*: Atypical Angina, dolore al petto che non segue tutte le caratteristiche della tipica angina
 - c. *NAP*: Non-anginal Pain, dolore toracico non correlato a cause cardiache
 - d. *ASY*: Asymptomatic, assenza di sintomi o dolore al petto
4. **RestingBP**: pressione arteriosa a riposo misurata in millimetri di mercurio (mm Hg)
5. **Cholesterol**: livello di colesterolo sierico (mg/dl)
6. **FastingBS**: glicemia a digiuno (valore booleano, 1: se > 120 mg/dl, 0: altrimenti)
7. **RestingECG**: risultati dell'elettrocardiogramma a riposo
 - a. *Normal*: normale
 - b. *ST*: anomalia dell'onda ST-T (inversione dell'onda T e/o sopraelevazione o depressione del tratto ST > 0.05 mV)
 - c. *LVH*: possibile o certa ipertrofia ventricolare sinistra secondo i criteri di Estes
8. **MaxHR**: massima frequenza cardiaca raggiunta, in range tra 60 e 202 bpm
9. **ExerciseAngina**: angina indotta dall'esercizio (booleano)
10. **Oldpeak**: depressione del tratto ST sull'ECG in valore numerico
11. **ST_Slope**: categoria del segmento ST al picco dell'esercizio fisico:
 - a. "Up" aumento;
 - b. "Flat" (piatto) nessuna variazione;
 - c. "Down" (discendente).

Il target è quello di individuare la presenza o meno di un Heart Disease; dunque possiamo categorizzare il problema come una classificazione binaria.

L'obiettivo principale di questo progetto è sviluppare un modello di machine learning in grado di prevedere la presenza o l'assenza di insufficienza cardiaca sulla base di queste caratteristiche cliniche.

Affrontare questo problema con tecniche di machine learning può portare a una diagnosi più rapida e accurata, migliorando gli esiti per i pazienti e ottimizzando le risorse mediche. Inoltre, l'analisi dei dati può contribuire a comprendere meglio i fattori di rischio più significativi, fornendo indicazioni utili per strategie preventive e interventi mirati.

Questo progetto si concentrerà sulle seguenti fasi principali:

1. **Esplorazione e Preprocessing dei Dati**: Analisi statistica descrittiva e gestione dei dati mancanti o anomali.
2. **Costruzione dei Modelli**: Implementazione e confronto di diversi algoritmi di machine learning.
3. **Valutazione delle Prestazioni**: Utilizzo di metriche appropriate per misurare l'efficacia del modello.
4. **Interpretazione e Applicazione dei Risultati**: Discussione sui risultati ottenuti e sulle possibili applicazioni pratiche.

Attraverso questo progetto, si mira a dimostrare come l'integrazione di dati clinici e algoritmi predittivi possa supportare le decisioni mediche, contribuendo alla lotta contro l'insufficienza cardiaca e alla promozione di una medicina preventiva e personalizzata. In particolare sarà interessante osservare le differenze di prestazioni di modelli con complessità differente.

Provenienza dataset

Questo dataset è stato creato combinando diversi dataset già disponibili in modo indipendente ma mai uniti in precedenza. In questo dataset, 4 dataset relativi a malattie cardiache sono stati combinati in base a 11 caratteristiche comuni, rendendolo il più grande dataset disponibile finora per scopi di ricerca su questo determinato ambito. I quattro dataset utilizzati per la sua creazione sono:

- **Cleveland Clinic Foundation (Cleveland, USA)**
- **Hungarian Institute of Cardiology (Budapest, Hungary)**
- **University Hospital (Zurich, Switzerland and Basel, Switzerland)**
- **V.A. Medical Center, Long Beach (USA)**

Totale: 920

Dati duplicati: 2 osservazioni

Dataset finale: 918 osservazioni

Analisi esplorativa

Statistiche descrittive

Analisi delle covariate e distribuzioni

Il dataset è costituito da 918 istanze, per ciascuna delle quali sono registrati i valori delle 11 covariate.

```
RangeIndex: 918 entries, 0 to 917
Data columns (total 12 columns):
#   Column                Non-Null Count  Dtype  
---  -
0   Age                   918 non-null   int64  
1   Sex                   918 non-null   object  
2   ChestPainType         918 non-null   object  
3   RestingBP             918 non-null   int64  
4   Cholesterol            918 non-null   int64  
5   FastingBS             918 non-null   int64  
6   RestingECG            918 non-null   object  
7   MaxHR                 918 non-null   int64  
8   ExerciseAngina        918 non-null   object  
9   Oldpeak               918 non-null   float64 
10  ST_Slope              918 non-null   object  
11  HeartDisease          918 non-null   int64  
dtypes: float64(1), int64(6), object(5)
memory usage: 86.2+ KB
```

Come si può osservare dall'immagine, non sono presenti valori nulli per nessuna delle feature. È bene cominciare con un processo di sistemazione del dataset e data cleaning per assicurare la qualità dei dati. Tipicamente questo processo si compone della gestione dei:

- duplicati

- valori mancanti
- outlier
- tipologia di dato

In merito ai valori mancanti, si osserva che non sono presenti; i duplicati sono stati eliminati e gli outlier non sono stati gestiti in quanto il numero di istanze è piuttosto ridotto e dalla analisi di distribuzione che si osserva successivamente non sono particolarmente significativi.

Variabile Target

Per quanto riguarda la tipologia del dato, è stato effettuato un cast della variabile target "HeartDisease" a tipo **boolean** in quanto la rappresentazione dei valori 0 e 1 ha come semantica la presenza o meno del disturbo cardiaco.

Classificazione delle Feature

Il dataset è stato organizzato distinguendo tre tipologie di variabili:

1. **Feature Numeriche** (num_features): Age, RestingBP, Cholesterol, MaxHR, Oldpeak
2. **Feature Binarie** (bin_features): Sex, FastingBS, ExerciseAngina
3. **Feature Categorie Multiple** (cat_features): ChestPainType, RestingECG, ST_Slope

Codifica delle Variabili Binarie

Le feature binarie sono state trasformate per renderle più interpretabili e adatte alle analisi successive:

- **Sex**: mappata da {'M': 1, 'F': 0} e convertita a tipo intero
- **ExerciseAngina**: mappata da {'Y': 1, 'N': 0} e convertita a tipo intero
- **FastingBS**: mantenuta nella sua forma originale (0/1)

Questa codifica mantiene la semantica binaria (presenza/assenza della caratteristica) rendendo esplicita la correlazione tra valore numerico e significato reale.

Codifica delle Variabili Categorie Multiple

I dati di tipo 'object' rappresentano variabili categoriche che, per renderli adatti alle analisi e all'applicazione dei modelli successivamente, sono stati codificati con **OneHotEncoder** messo a disposizione da scikit-learn. Questa scelta è stata fatta dopo aver osservato che ciascuna di queste feature possedeva un numero ridotto di valori unici. OneHotEncoder prende una feature (colonna del dataframe) e ne crea una nuova per ciascun valore unico che si osserva della feature in questione, assegnando il valore 1 se l'istanza aveva quel valore nel record originale e 0 altrimenti.


Ora che il dataset è stato "pulito", si osservi la distribuzione dei dati.

Distribuzione dei dati

	Age	RestingBP	Cholesterol	FastingBS	MaxHR	Oldpeak	HeartDisease
count	918.000000	918.000000	918.000000	918.000000	918.000000	918.000000	918.000000
mean	53.510893	132.396514	198.799564	0.233115	136.809368	0.887364	0.553377
std	9.432617	18.514154	109.384145	0.423046	25.460334	1.066570	0.497414
min	28.000000	0.000000	0.000000	0.000000	60.000000	-2.600000	0.000000
25%	47.000000	120.000000	173.250000	0.000000	120.000000	0.000000	0.000000
50%	54.000000	130.000000	223.000000	0.000000	138.000000	0.600000	1.000000
75%	60.000000	140.000000	267.000000	0.000000	156.000000	1.500000	1.000000
max	77.000000	200.000000	603.000000	1.000000	202.000000	6.200000	1.000000

Notiamo che tutte le feature hanno media e deviazione standard differenti. HeartDisease come reso noto in precedenza è la variabile target e ha valori 0 ed 1.

I grafici delle distribuzioni possono rendere più immediata la comprensione delle feature numeriche.



La distribuzione dell'età (Age) è approssimativamente normale, con la maggior parte dei pazienti tra i 47 e i 60 anni. La presenza di code leggere su entrambi i lati indica una buona rappresentatività anche delle fasce più giovani e più anziane.

La pressione sanguigna a riposo (RestingBP) mostra una distribuzione asimmetrica con un picco tra 120 e 140 mmHg.

Si noti che in Cholesterol il 18.74% dei valori totali sono zero, visto che è impossibile che un paziente abbia valori a zero di colesterolo, quei valori rappresentano valori mancanti nonostante non siano risultati dall'esplorazione iniziale. Per risolvere questo problema di data quality si è pensato di inserire al posto dei valori nulli, la media dei valori non nulli del dataset. Dato che la curva rappresentata dai valori non nulli segue circa una distribuzione gaussiana, la media può essere una buona approssimazione del valore.

La feature "MaxHR" relativa alla frequenza cardiaca massima registrata mostra una distribuzione quasi normale con un picco intorno ai 125-140 bpm.


Distribuzione fortemente asimmetrica nella feature "Oldpeak" con la maggior parte dei valori vicini allo 0. Valori superiori a 2 potrebbero essere indicativi di un'ischemia significativa.

	Age	RestingBP	Cholesterol	MaxHR	Oldpeak
kurtosis	-0.386140	3.271251	6.257803	-0.448248	1.203064
skew	-0.195933	0.179839	1.373396	-0.144359	1.022872

Dando un'occhiata ai valori di curtosi e asimmetria, le osservazioni precedenti sono confermate, una "campana" molto appuntita (leptocurtica) per le covariate RestingBP e Cholesterol e una asimmetria della curva accentuata in Cholesterol e Oldpeak positivamente che indica curve lunghe a destra delle medie rispettive.


Ora analizziamo le variabili binarie e osserviamo come sono distribuite nel dataset:

Count of Binary features



Nel dataset è evidente una predominanza maschile: circa 700 pazienti sono uomini, mentre le donne sono circa 200. Questo sbilanciamento potrebbe influenzare le previsioni del modello, soprattutto se il sesso risulta essere una variabile rilevante. La variabile che indica la presenza di angina da sforzo mostra che la maggior parte dei pazienti non ne soffre (**N**), mentre circa il 40% presenta angina indotta dall'esercizio (**Y**). Infine la variabile binaria "FastingBS" presenta la maggior parte dei valori a 0 (glicemia normale) e una minoranza a 1 (glicemia elevata).


Infine analizziamo la distribuzione delle variabili categoriche:



Analizzando la tipologia di dolore toracico, si nota che la categoria **ASY** (asintomatico) è la più frequente, seguita da **NAP** (dolore atipico) e **ATA** (angina tipica). La categoria **TA** (angina tipica) appare invece piuttosto rara.

Osservando la distribuzione dei risultati dell'elettrocardiogramma a riposo, circa la metà dei pazienti mostra un tracciato **normale**, mentre le categorie **ST** e **LVH** sono meno frequenti ma rappresentate in modo simile.

Infine, analizzando la pendenza del segmento ST, si nota una leggera prevalenza della categoria **Flat**, seguita da **Up**, mentre **Down** risulta meno comune.




Il target presenta una distribuzione equilibrata tra i casi positivi e negativi di malattie cardiache, con le seguenti percentuali:

- **True:** 55,34%
- **False:** 44,66%

In relazione ai modelli di machine learning descritti nei capitoli successivi, un modello triviale utilizzato come baseline — che assegna sempre il valore *True* a ogni istanza — otterrebbe un'accuratezza pari al **55,34%**

Analisi rispetto al target


Invece che osservare la distribuzione che assumono le singole variabili, proviamo ad osservarne la distribuzione rispetto al valore target “HeartDisease”. Visualizziamo le variabili continue attraverso dei boxplot.



I grafici evidenziano fatti significativi.


L'età dei pazienti che presentano un HeartDisease è leggermente maggiore di quella dei pazienti sani, con qualche caso particolare tra i 30 e i 40 anni. I soggetti positivi mostrano una massima frequenza cardiaca raggiunta leggermente inferiore a quella dei soggetti sani e un "Oldpeak" (dunque Depressione ST nell'ECG) con una curtosi inferiore dei soggetti sani e dunque una distribuzione più ampia. Le variabili coinvolte in queste osservazioni potrebbero essere significative ai fini delle predizioni.

Si osservi ora se emergono nuove informazioni rilevanti dalle feature binarie.




È evidente un forte sbilanciamento nella composizione del dataset in cui le istanze “malate” sono in forte prevalenza maschili, questo potrebbe indurre la presenza di bias nei modelli e una rappresentazione inesatta del dominio. Molto significativa invece la feature di ExerciseAngina che è molto probabile che sia Yes se il soggetto in questione ha HeartDisease (ma non è altrettanto probabile che sia a No se il soggetto è sano)

Viene spontaneo chiedersi se donne e uomini riscontrino dolori al petto con una distribuzione differente.



Dal grafico emerge che i soggetti di sesso maschile siano prevalente asintomatici per quanto riguarda il dolore al petto, mentre per le donne anche probabilmente per natura anatomica presentino una distribuzione delle tipologie di dolore al petto più omogenea, nonostante la tipologia leggermente dominante sia sempre la categoria Asintomatic.


Infine analizziamo anche la correlazione tra arresto cardiaco e le feature categoriche:



“ChestPain” evidenzia come sia molto probabile che chi ha “HeartDisease” non abbia dolore toracico e che sia appunto ASYmptomatic. Gli ECG a riposo possono essere significativi per fare predizioni in merito a un disturbo cardiovascolare se presentano anomalie di picco (ST). I valori Flat e Down per la feature ST_Slope sono piuttosto rilevanti per identificare il disturbo nonostante occorran con frequenza significativamente diversa.


Analisi di correlazione

Ricerchiamo ora delle possibili correlazioni tra le variabili numeriche.



Non sono presenti correlazioni significative. Un accenno di correlazione negativa si individua tra le feature MaxHR e Age. È intuitivo pensare che ad un'età più elevata la frequenza massima raggiungibile dal cuore si riduca leggermente.

Inoltre il grafico successivo che può rappresentare il legame che unisce Age e HeartDisease può evidenziare che il rischio di contrarre un disturbo cardiaco può aumentare con l'avanzare dell'età.



È probabile che la varianza del grafico si vada ad appiattire in un dataset più ampio.

Principal Component Analysis

Il Dataset ottenuto finora contiene 5 feature continue, Si può provare ad effettuare una analisi esplorativa con Principal Component Analysis.

Nella sezione dedicata alla PCA, l'obiettivo era ridurre la dimensionalità dei dati mantenendo la maggior parte dell'informazione presente. Il processo è stato eseguito nei seguenti passaggi:

1. **Preprocessing dei dati:**


È stata effettuata una standardizzazione delle feature numeriche mediante lo `StandardScaler`, in modo che tutte le variabili avessero media zero e varianza unitaria. Questo passaggio è cruciale per evitare che variabili con scale differenti influiscano in modo sproporzionato sulla PCA.

2. **Applicazione della PCA:**

Dopo la standardizzazione, la PCA è stata calcolata sul set di dati normalizzato. È stata considerata l'intera gamma di componenti principali per valutare la varianza spiegata da ciascuna.

3. **Analisi della varianza spiegata:**

- È stato generato un grafico che mostra la **varianza spiegata** da ciascuna componente principale. Questo aiuta a identificare quante componenti sono necessarie per catturare una percentuale significativa dell'informazione originale.
- È stato creato anche lo **scree plot**, che mostra sia la varianza spiegata singola sia quella cumulativa. Questo grafico è utile per individuare il cosiddetto "gomito" (elbow), che suggerisce il numero ottimale di componenti da mantenere.




	Eigenvalue	Variance Percent	Cumulative Variance Percent
Component 1	1.702267	34.008252	34.008252
Component 2	1.012787	20.233682	54.241934
Component 3	0.880805	17.596920	71.838853
Component 4	0.829078	16.563507	88.402360
Component 5	0.580514	11.597640	100.000000

Risultati principali

- La varianza spiegata dalle prime componenti principali ha mostrato che una piccola parte di esse è sufficiente a mantenere la maggior parte dell'informazione.
- Dal grafico della varianza cumulativa, si è osservato che con 4 componenti si raggiungeva una soglia di varianza spiegata superiore al **88%**, suggerendo una riduzione della dimensionalità senza perdita rilevante di informazione.

È stato creato inoltre un grafico 2D che mostra le correlazioni tra le variabili iniziali e le prime due componenti principali. Ciascun vettore consente di ricavare diverse informazioni: due vettori correlati positivamente sono raggruppati insieme, mentre in caso di correlazione negativa si trovano in quadranti opposti, e infine è possibile quantificare la qualità di una singola feature in base alla distanza dall'origine.



Cholesterol, per esempio, è molto correlata con la componente principale 2 (asse y) e quasi per nulla correlata con la componente principale 1 (asse x), il che può significare che PC1 e Cholesterol rappresentano all'incirca una stessa caratteristica delle istanze.

Modelli applicati

Per l'applicazione dei modelli di Machine Learning si è utilizzato il dataset originale (non quello ridotto con l'applicazione di PCA), con l'opportuna pulizia e trasformazione, descritta in precedenza.

Per la fase di cross validation, è stato utilizzato il training set a causa del numero limitato di istanze disponibili. Questa scelta è stata fatta per sfruttare al massimo i dati disponibili e ottenere comunque una stima affidabile delle prestazioni del modello. Tuttavia, in presenza di un dataset più ampio, sarebbe stato preferibile utilizzare un validation set separato per evitare possibili bias e garantire una valutazione più robusta e generalizzabile del modello.

Sono stati quindi definiti i set di dati da utilizzare per l'addestramento (e validation) e test separando opportunamente insieme di feature e la variabile target "HeartDisease", con una proporzione di 80% training e 20% test.

I modelli applicati sono alberi di decisione, support vector machines e reti neurali. Prima di costruire gli ultimi due modelli è stata applicata la standardizzazione con StandardScaler, in quanto questi risultano essere scale-sensitive.

Per l'ottimizzazione degli iperparametri tramite Grid Search dei modelli ottimizzati, è stata scelta la metrica F1-score come funzione di scoring, in quanto risulta essere la scelta più appropriata per dataset che presentano sbilanciamento delle classi come quello in analisi.

Alberi di decisione


Come primo modello è stato scelto l'albero di decisione, poiché si presta particolarmente bene alla classificazione binaria. Tra i principali vantaggi di questo modello vi sono la semplicità, l'efficienza e l'interpretabilità dei risultati. Quest'ultimo aspetto è particolarmente rilevante nel contesto medico, in quanto permette di comprendere le motivazioni che portano a classificare un paziente in una determinata categoria, facilitando così l'analisi e l'interpretazione dei risultati.

In particolare sono stati costruiti 2 alberi di decisione:

- **Un albero naive:** con un approccio semplice ed immediato, utilizzando iperparametri di default per la creazione dell'albero, dunque non ponendo alcun limite rispetto alle dimensioni dell'albero in termini di nodi e profondità
- **Un albero ottimizzato:** Per ottimizzare la costruzione dell'albero di decisione, è stata utilizzata la Grid Search per selezionare i migliori iperparametri. In particolare, sono stati valutati diversi valori di `ccp_alpha`, `splitter`, `criterion`, `max_depth` e `max_features`, con l'obiettivo di massimizzare l'accuracy sul test. Questo approccio consente di identificare la combinazione ottimale di parametri, migliorando le prestazioni del modello rispetto a una configurazione predefinita.

Costruzione e Training con Approccio Naive

Approfondendo l'approccio naive, l'albero è stato costruito utilizzando la libreria sklearn nel modo più semplice possibile, ovvero lasciando gli iperparametri al valore di default.



L'addestramento del modello è stato eseguito utilizzando la funzione `fit()` di `scikit-learn`, applicata ai dati precedentemente suddivisi in training e test. A fine esecuzione possiamo osservare la struttura finale dell'albero che ha una profondità massima di 13. Inoltre è stata calcolata anche l'accuracy di training:

```
Accuracy di training: 1.0000
```


```
tempo training albero di decisione naive in secondi: 0.0134
```

Valutazione delle Performance Naive

Dopo l'addestramento si è andato a valutare il modello, effettuando predizioni e visualizzando misure e grafici delle performance.

La matrice di confusione è una tabella utilizzata per valutare le prestazioni di un modello di classificazione. Essa confronta le predizioni del modello con i valori reali, mostrando quanti campioni sono stati classificati correttamente e quanti sono stati erroneamente assegnati ad altre classi. Per un problema di classificazione binaria, la matrice di confusione è strutturata come segue:

	Predetto Positivo	Predetto Negativo
Reale Positivo	Vero Positivo (TP)	Falso Negativo (FN)
Reale Negativo	Falso Positivo (FP)	Vero Negativo (TN)



Misure di performance

Sono state calcolate ulteriori misure di performance per una valutazione più dettagliata:

Misure di performance per ogni classe target: misure per il target che forniscono informazioni specifiche sulle prestazioni del modello per ciascuna classe di destinazione.

- **Precision:** misura la proporzione di istanze identificate correttamente come appartenenti a una determinata classe rispetto a tutte le istanze identificate come appartenenti a quella classe. È calcolata come il rapporto tra i veri positivi (TP) e la somma dei veri positivi e dei falsi positivi (FP).
- **Recall:** misura la proporzione di istanze di una determinata classe che sono state identificate correttamente dal modello rispetto a tutte le istanze effettivamente appartenenti a quella classe. È calcolato come il rapporto tra i veri positivi (TP) e la somma dei veri positivi e dei falsi negativi (FN).
- **F1-score:** è la media armonica di precision e recall. L'F1-score è calcolato come il rapporto tra due volte il prodotto di precision e recall e la loro somma
- **Support:** rappresenta il numero di campioni di test che appartengono a ciascuna classe target.

Misure di performance globali: misure che forniscono una valutazione complessiva delle prestazioni del modello sull'intero insieme di dati di test.

misure di performance albero di decisione a livello di classe:

	precision	recall	f1-score	support
False	0.74	0.77	0.75	82
True	0.81	0.78	0.80	102
accuracy			0.78	184
macro avg	0.77	0.78	0.78	184
weighted avg	0.78	0.78	0.78	184

Misure di performance globali decision tree naive

Accuracy: 0.7771739130434783
Precision: 0.8080808080808081
Recall: 0.7843137254901961
F1-score: 0.7960199004975125

Curva ROC e AUC


La curva ROC è un grafico che rappresenta le prestazioni di un classificatore binario al variare della soglia di decisione. Sull'asse x si trova il tasso di falsi positivi (FPR), mentre sull'asse y si trova il tasso di veri positivi (TPR), noto anche come recall o sensibilità.

Una curva ROC più vicina all'angolo in alto a sinistra indica un modello più performante, poiché implica un alto tasso di veri positivi e un basso tasso di falsi positivi.

AUC

L'AUC (Area Under the Curve) è un valore numerico che rappresenta l'area sotto la curva ROC. Indica la capacità del modello di distinguere tra le classi:

- $AUC = 1$ → il modello distingue perfettamente tra le due classi.
- $AUC = 0.5$ → il modello è equivalente a una classificazione casuale.
- $AUC < 0.5$ → il modello è peggiore di una scelta casuale.



La curva ROC ottenuta dal modello naive ha prodotto un AUC di 0.78, un valore che indica una buona capacità discriminante. Sebbene non sia ottimale, è comunque significativamente superiore al valore casuale (0.5) e discretamente vicino al massimo teorico (1.0), suggerendo che il modello è in grado di distinguere le due classi in maniera discreta.

Costruzione con Approccio ottimale

Per ottimizzare l'albero di decisione tramite la scelta dei migliori iperparametri abbiamo utilizzato grid search, in particolare abbiamo scelto la funzione GridSearchCV della libreria sklearn. Per prima cosa abbiamo definito un nuovo modello di albero di decisione in maniera analoga a quello definito nell'approccio naive. Successivamente abbiamo identificato gli iperparametri da ottimizzare:


- `ccp_alpha`: parametro di complessità per la potatura dell'albero. Un valore elevato tende a ridurre l'albero alla sola radice, mentre un valore pari a 0 consente la crescita senza restrizioni.
- `criterion`: funzione per misurare la qualità dello split (gini, entropy)
- `max_depth`: la profondità massima che può raggiungere l'albero
- `max_features`: numero di feature utilizzate per trovare il migliore split
- `splitter`: la politica utilizzata per scegliere il miglior split ad ogni nodo

risultati ottenuti:

```
{'ccp_alpha': 0.0, 'criterion': 'gini', 'max_depth': 3, 'max_features': None, 'splitter': 'random'}
```

```
tempo calcolo iperparametri ottimali con grid search in secondi: 4.1854
```

Una volta trovato gli iperparametri ottimali procedo con la costruzione e il training dell'albero di decisione



Accuracy di training: 0.8542

tempo training albero di decisione ottimale in secondi: 0.0042

Notiamo che l'accuracy sul training set è diminuita rispetto al modello naive, ciò significa che probabilmente l'overfitting si è ridotto. Dall'albero si conferma quanto ottenuto utilizzando gli iperparametri restituiti dalla Grid Search (per esempio la profondità massima di 5)

Valutazione performance con albero con approccio ottimale



Dopo l'addestramento si è andato a valutare il modello, effettuando predizioni e visualizzando misure e grafici delle performance.

Misure di performance per ogni classe target:

Misure di performance albero di decisione ottimizzato a livello di classe:				
	precision	recall	f1-score	support
False	0.82	0.79	0.81	82
True	0.84	0.86	0.85	102
accuracy			0.83	184
macro avg	0.83	0.83	0.83	184
weighted avg	0.83	0.83	0.83	184

Misure di performance globali decision tree optimized

Accuracy: 0.8315217391304348
Precision: 0.8380952380952381
Recall: 0.8627450980392157
F1-score: 0.8502415458937198



Dall'analisi dei risultati, si osserva che l'albero di decisione ottimizzato ha ottenuto prestazioni complessivamente migliori rispetto al modello naive.

L'albero ottimizzato risulta preferibile in quanto abbiamo riscontrato:

1. Miglioramento di tutte le performance globali misurate e anche di quelle relative alle classi target
2. Migliore area ROC-AUC: passa da 0.78 a 0.88, indicando una capacità superiore nel distinguere tra le classi.
3. Meno overfitting: pur avendo un accuracy di training inferiore rispetto all'approccio naive, il miglioramento sulle metriche di test suggerisce un modello più generalizzabile.

Support Vector Machines

Il secondo modello presentato sono le Support Vector machine. Il modello sembra adatto a questo tipo di problema in quanto può gestire sia relazioni lineari che non lineari grazie all'uso di kernel. SVM massimizza il margine tra le classi e, con gli opportuni parametri, generalizza bene e ha rischio ridotto di overfitting, caratteristica utile con dataset medici complessi. Inoltre, è robusta anche con un numero limitato di campioni, situazione comune nelle diagnosi cardiache.

Sono state sviluppate due diverse architetture di support vector machines:

- **SVM naive:** Un modello di base costruito con un approccio immediato, senza particolari ottimizzazioni, in seguito i dettagli.
- **SVM ottimizzato:** Un modello più sofisticato, in cui gli iperparametri sono stati selezionati per migliorare la capacità di classificazione. Per ottimizzarli, è stata utilizzata la tecnica del grid search, al fine di individuare la combinazione di parametri che migliori le prestazioni complessive del modello.

Costruzione e Training con Approccio Naive

Per la costruzione del modello naive, abbiamo lasciato tutti gli iperparametri ai loro valori di default: (*, C=1.0, kernel='rbf', degree=3, gamma='scale', coef0=0.0, shrinking=True, probability=False, tol=0.001, cache_size=200, class_weight=None, verbose=False, max_iter=-1, decision_function_shape='ovr', break_ties=False, random_state=None)

Gli unici valori che sono stati modificati sono stati:

- **random state=42:** Per garantire la riproducibilità dei risultati e una comparazione più significativa con gli altri modelli anch'essi addestrati con lo stesso valore di random_state
- **probability=True:** per ottenere, oltre ai valori della decision function, anche stime di probabilità calibrate per ciascuna classe. Questo ci ha consentito di utilizzare direttamente le probabilità previste (tramite predict_proba) per il calcolo della curva ROC

Accuracy di training: 0.8965

tempo training SVM naive in secondi: 0.0374


Di seguito ho riportato i risultati in fase di test:


Misure di performance support vector machines a livello di classe:

	precision	recall	f1-score	support
False	0.85	0.85	0.85	82
True	0.88	0.88	0.88	102
accuracy			0.87	184
macro avg	0.87	0.87	0.87	184
weighted avg	0.87	0.87	0.87	184

Misure di performance globali svm naive

Accuracy: 0.8695652173913043
Precision: 0.8823529411764706
Recall: 0.8823529411764706
F1-score: 0.8823529411764706





Questi risultati indicano prestazioni molto buone, con valori delle metriche elevati. Il modello gestisce bene sia i falsi positivi che i falsi negativi. Anche la curva Roc ha valori molto buoni con un AUC pari a 0.94. Per essere un modello naive abbiamo ottenuto buone performance, ma vediamo se riusciamo ad ottenere risultati ancora migliori con l'ottimizzazione dei parametri

Costruzione e Training del modello ottimizzato

Il tuning degli iperparametri è un passaggio cruciale nell'ottimizzazione delle performance di un modello di machine learning, in particolare per modelli complessi come le macchine a vettori di supporto (SVM). In questo contesto, il processo di tuning si concentra sull'ottimizzazione dei principali iperparametri di un SVM, ovvero **C**, **kernel** e **gamma**. Il parametro **gamma** è coefficiente di scala, determina la forma della funzione di kernel (per le funzioni non lineari), influenzando la capacità del modello di adattarsi ai dati. I possibili valori per **kernel** includono 'rbf', 'poly' e 'linear', ciascuno dei quali ha un impatto significativo sulle performance del modello. Utilizzando una **GridSearchCV**, si esegue una ricerca su una griglia di combinazioni di valori per questi iperparametri, al fine di trovare quella che ottimizza l'f1 score del modello sui dati di addestramento.

Il modello migliore trovato ha i seguenti iperparametri:

```
Iperparametri ottimali: {'C': 25, 'gamma': 0.01, 'kernel': 'rbf'}
```

```
tempo calcolo iperparametri ottimali con grid search in secondi: 30.5698
```

Valutazione performance con SVM con approccio ottimale

```
Accuracy di training: 0.8842
```

```
tempo calcolo SVM ottimale in secondi: 0.0414
```

misure di performance di classe:

Misure di performance support vector machines ottimizzato a livello di classe:				
	precision	recall	f1-score	support
False	0.86	0.85	0.86	82
True	0.88	0.89	0.89	102
accuracy			0.88	184
macro avg	0.87	0.87	0.87	184
weighted avg	0.87	0.88	0.87	184

Con un'accuratezza di 0.88, il modello si comporta in maniera ottima

```
Misure di performance globali svm optimized  
  
Accuracy: 0.875  
Precision: 0.883495145631068  
Recall: 0.8921568627450981  
F1-score: 0.8878048780487805
```



La media ponderata (weighted average) per precisione, recall e f1-score è 0.87, il che conferma che il modello è equilibrato nel trattare entrambe le classi.

Accuracy: L'accuratezza del modello è **0.875**, il che significa che il modello ha classificato correttamente circa l'88% delle istanze totali. Questo è un ottimo risultato, indicando che la maggior parte delle previsioni fatte dal modello sono corrette.

Precision: La precisione è **0.88**, il che implica che, tra tutte le istanze classificate come positive (True), circa l'88% sono effettivamente corrette. Questo valore suggerisce che il modello è abbastanza accurato nel fare previsioni positive, riducendo i falsi positivi.

Recall: Il recall è **0.89**, che indica che il modello è in grado di identificare l'89% delle istanze positive (True). Questo valore è piuttosto elevato, suggerendo che il modello è particolarmente bravo a trovare i casi positivi, riducendo al minimo i falsi negativi.

F1-score: Il f1-score è **0.887**, che rappresenta una media armonica tra precisione e recall. Questo valore è molto buono, indicando che il modello riesce a mantenere un buon equilibrio tra evitare falsi positivi (precisione) e catturare tutti i casi positivi (recall).



La curva si posiziona ben al di sopra della diagonale blu tratteggiata (linea di riferimento per un classificatore casuale), segnalando che il modello ha buone capacità discriminative.

L'area sotto la curva (AUC) è 0.94, valore elevato che indica un'ottima prestazione complessiva nel distinguere tra le classi.

La curva è ripida all'inizio (vicino allo 0 sull'asse x), suggerendo che il modello raggiunge un alto tasso di veri positivi con pochi falsi positivi, qualità importante in ambito medico.

Anche in questo caso il modello SVM risulta preferibile in quanto abbiamo riscontrato:

1. **Miglioramento di tutte le performance** globali misurate e anche di quelle relative alle classi target
2. **Area ROC-AUC costante:** rimane con un valore piuttosto alto di 0.94

3. **Meno overfitting:** pur avendo un accuracy di training inferiore rispetto all'approccio naive, il miglioramento sulle metriche di test suggerisce un modello più generalizzabile.

Reti neurali

l'ultimo modello usato è stato la rete neurale, strumento estremamente versatile in grado di individuare relazioni complesse nei dati. Questo approccio risulta particolarmente utile quando i pattern sottostanti non sono immediatamente evidenti o seguono dinamiche non lineari. Grazie alla sua struttura a più livelli, la rete può apprendere autonomamente le caratteristiche più rilevanti e affinare progressivamente la propria capacità predittiva.

Sono state sviluppate due diverse architetture di rete neurale:

- **Rete naive:** Un modello di base costruito con un approccio immediato, utilizzando gli iperparametri di default senza particolari ottimizzazioni.
- **Rete ottimizzata:** Un modello più sofisticato, in cui gli iperparametri sono stati selezionati per migliorare la capacità di classificazione. Per ottimizzarli, è stata utilizzata la tecnica del grid search, già impiegata negli altri modelli, al fine di individuare la combinazione di parametri che minimizza la loss di validazione e migliora le prestazioni complessive della rete.

Costruzione e Training con Approccio Naive

Per affrontare il problema di classificazione binaria, è stata implementata una rete neurale con Keras.

Prima di addestrare il modello, è stata applicata la standardizzazione ai dati di input, una pratica essenziale nelle reti neurali per garantire una convergenza più stabile e veloce. Per questo scopo, è stato utilizzato lo StandardScaler di Scikit-Learn:

Il modello implementato utilizza la classe sequential di Keras, con la seguente struttura:

- Primo strato nascosto: 100 neuroni con attivazione ReLU
- Secondo strato nascosto: 50 neuroni con attivazione ReLU
- Strato di output: 1 neurone con attivazione sigmoid, adatto alla classificazione binaria

Il modello è stato compilato utilizzando la funzione di perdita binary_crossentropy, adatta a target binari e adam come optimizer.

Il training è stato effettuato utilizzando l'apposita funzione fit offerta da Keras, utilizzando i dati del dataset suddivisi in precedenza. Il batch_size è stato imposto a 32, valore di default se non specificato, mentre il modello è stato allenato su 50 epoche. Inoltre come per tutti i modelli è stato fissato il random_state a 42 per garantire la riproducibilità dei risultati

```
Training Loss: 0.1025
Training Accuracy: 0.9741
```


```
tempo training rete neurale naive in secondi: 3.9101
```

Valutazione performance con rete neurale naive


Misure di performance rete neurale a livello di classe:				
	precision	recall	f1-score	support
False	0.77	0.83	0.80	82
True	0.85	0.80	0.83	102
accuracy			0.82	184
macro avg	0.81	0.82	0.81	184
weighted avg	0.82	0.82	0.82	184

```
Misure di performance globali neural network naive
```

```
Accuracy: 0.8152173913043478  
Precision: 0.8541666666666666  
Recall: 0.803921568627451  
F1-score: 0.8282828282828283
```



```
Test Loss: 0.5142  
Test Accuracy: 0.8152
```



Dall'analisi dei risultati emerge che la rete neurale naive mostra una elevata accuratezza sul training set (97.41%), ma presenta un Test Loss piuttosto alto (0.5142) rispetto al Training Loss (0.1025). Questo è un chiaro segnale di overfitting, ovvero la rete si adatta molto bene ai dati di addestramento ma fatica a generalizzare su dati nuovi. Inoltre, la differenza tra training e test accuracy conferma questa ipotesi: l'accuratezza sui dati di test è più bassa (81.52%), indicando che la rete potrebbe essersi specializzata troppo sul dataset di training. Tuttavia, le metriche di precisione, recall e F1-score sono comunque buone, con un leggero vantaggio della classe False rispetto alla classe True. La matrice di confusione mostra che la rete commette più errori nel classificare i falsi positivi. Infine, il valore della AUC-ROC pari a 0.90 è un buon risultato, indicando una discreta capacità di discriminare tra le due classi.

Costruzione e Training con Approccio ottimale

Dopo aver implementato un primo modello di rete neurale con un set di iperparametri scelto manualmente, si è passati a una fase di ottimizzazione più avanzata per migliorare le prestazioni del classificatore. Per ottimizzare gli iperparametri, è stato adottato un approccio basato sulla ricerca esaustiva tramite Grid Search, utilizzando una pipeline che comprendeva la normalizzazione dei dati e l'addestramento della rete neurale. Questa tecnica consente di testare sistematicamente diverse combinazioni di parametri e selezionare la configurazione che garantisce le migliori prestazioni in termini di accuratezza. Gli iperparametri selezionati sono stati:

Funzione di attivazione:

La funzione di attivazione è un componente fondamentale delle reti neurali, in quanto introduce non linearità nel modello, permettendogli di apprendere relazioni complesse tra le variabili di input. Come opzioni nella grid search c'erano tanh e relu

Dimensione del batch:

La dimensione del batch determina il numero di campioni elaborati prima che il modello aggiorni i pesi tramite retropropagazione. Batch più piccoli tendono a introdurre più rumore nella discesa del gradiente, mentre batch troppo grandi possono rallentare il processo di apprendimento e richiedere più memoria. Come opzioni nella grid search c'erano 16 e 32

Numero di epoche

Le epoche rappresentano il numero di volte in cui l'intero dataset viene utilizzato per addestrare la rete neurale. Come opzioni nella grid search c'erano 50 e 100 epoche

Struttura dei layer nascosti:

Questo parametro definisce il numero di neuroni presenti nei layer nascosti della rete. Come opzioni nella grid search c'erano 50 e 100 neuroni

Ottimizzatore:

L'ottimizzatore è l'algoritmo che gestisce l'aggiornamento dei pesi della rete durante l'addestramento. Abbiamo utilizzato per questo campo unicamente l'ottimizzatore adam in quanto risulta essere una soluzione nota per la sua solidità e per risparmiare sui tempi di esecuzione. Infatti l'ottimizzatore era uno degli iperparametri che andava ad incidere meno sulle performance e quindi il più sacrificabile per avere un grosso risparmio in termini di tempo di esecuzione

Dropout:

è una tecnica di regolarizzazione utilizzata nelle reti neurali per prevenire l'overfitting e migliorare la capacità di generalizzazione del modello. L'idea principale è disattivare casualmente alcuni neuroni durante l'addestramento, impedendo alla rete di dipendere troppo da specifici percorsi di attivazione e forzandola a imparare rappresentazioni più robuste. Come opzioni nella grid search c'erano 0.2 e 0.3

Iperparametri ottimali

```
{'model__activation': 'relu', 'model__batch_size': 32, 'model__dropout_rate': 0.3, 'model__epochs': 100, 'model__hidden_layer_sizes': (100,), 'model__optimizer': 'adam'}
```

```
tempo calcolo iperparametri ottimali con grid search in secondi: 209.0612
```

Costruzione e training con approccio ottimale

La costruzione ed il training per la rete ottimale segue lo stesso procedimento della rete naive, ma questa volta vengono utilizzati gli iperparametri ottimali appena ricavati al posto di quelli di default della rete naive.

```
Training Loss: 0.2248  
Training Accuracy: 0.9101
```

```
tempo training rete neurale ottimizzata in secondi: 5.8961
```


Rispetto alla rete naive, abbiamo riscontrato un peggioramento sia della training loss che della training accuracy nel modello ottimizzato. Tuttavia, questo non rappresenta un aspetto negativo, ma piuttosto un'indicazione che la rete naive soffriva di overfitting. Al contrario, il

modello ottimizzato mostra una maggiore capacità di generalizzazione, come confermato dai migliori risultati ottenuti sul test set, riportati di seguito.


Valutazione performance con rete neurale ottimizzata

misure di performance rete neurale ottimizzata a livello di classe:				
	precision	recall	f1-score	support
False	0.85	0.84	0.85	82
True	0.87	0.88	0.88	102
accuracy			0.86	184
macro avg	0.86	0.86	0.86	184
weighted avg	0.86	0.86	0.86	184

```
Misure di performance globali neural network optimized
Accuracy: 0.8641304347826086
Precision: 0.8737864077669902
Recall: 0.8823529411764706
F1-score: 0.8780487804878049
```



```
Test Loss: 0.3578
Test Accuracy: 0.8641
```

la rete neurale ottimizzata presenta un approccio più bilanciato tra training e test, con una Training Accuracy leggermente inferiore (91.01%) rispetto alla rete naive, ma con una perdita ridotta sui dati di test (0.3578 invece di 0.5142). Questo suggerisce che l'ottimizzazione ha portato a una migliore generalizzazione del modello, riducendo il rischio di overfitting. L'accuratezza sui dati di test è anch'essa migliorata rispetto a quella della rete naive (86% contro 82%). Inoltre la diminuzione del Test Loss conferma una gestione più efficace degli errori. Le metriche di precision, recall e F1-score hanno registrato tutte un miglioramento delle performance, rispetto alla versione naive. La matrice di confusione mostra un miglioramento delle performance registrando una diminuzione dei falsi positivi. Infine il valore della AUC-ROC è migliorato (0.93 rispetto a 0.90), segno che la capacità di discriminare tra le classi è aumentata.


In conclusione, la rete neurale ottimizzata risulta essere la scelta migliore, in quanto riduce il rischio di overfitting, garantisce una migliore generalizzazione e registra valori significativamente più alti delle metriche. Il miglioramento dell'AUC-ROC è un ulteriore indicatore che la rete ha affinato la sua capacità di separare correttamente le classi.

Confronto risultati

IMPROVEMENTS TABLE (% Improvement: Optimized vs Naive)					
Model	Accuracy	Precision	Recall	F1 Score	Average
Decision Tree	+6.99%	+3.71%	+10.00%	+6.81%	+6.88%
SVM	+0.63%	+0.13%	+1.11%	+0.62%	+0.62%
Neural Network	+6.00%	+2.30%	+9.76%	+6.01%	+6.02%

Come prevedibile gli algoritmi ottimizzati hanno registrato performance migliori nella totalità dei casi analizzati. In particolare si può osservare come i modelli che hanno avuto un


miglioramento più importante delle performance grazie all’ottimizzazione degli iperparametri sono stati gli alberi di decisione e le reti neurali con circa il 6% di miglioramento tra le 2 versioni. Invece SVM ha registrato un miglioramento molto più moderato dello 0.62%



MODEL RANKINGS			

Naive Models Ranking:			
Metric	1°	2°	3°
Accuracy	SVM (0.8696)	Neural Network (0.8152)	Decision Tree (0.7772)
Precision	SVM (0.8824)	Neural Network (0.8542)	Decision Tree (0.8081)
Recall	SVM (0.8824)	Neural Network (0.8039)	Decision Tree (0.7843)
F1 Score	SVM (0.8824)	Neural Network (0.8283)	Decision Tree (0.7960)
Optimized Models Ranking:			
Metric	1°	2°	3°
Accuracy	SVM (0.8750)	Neural Network (0.8641)	Decision Tree (0.8315)
Precision	SVM (0.8835)	Neural Network (0.8738)	Decision Tree (0.8381)
Recall	SVM (0.8922)	Neural Network (0.8824)	Decision Tree (0.8627)
F1 Score	SVM (0.8878)	Neural Network (0.8780)	Decision Tree (0.8502)

ML Algorithms Timing Performance Analysis - Actual Results (Log Scale)



Dai grafici e dalle tabelle riportate si può osservare come il modello che ha registrato le migliori performance sia nel caso naive che in quello ottimizzato è stato **SVM** che ha registrato valori migliori in tutte le metriche analizzate. La sua superiorità rispetto agli altri modelli è netta per quanto riguarda i modelli naive, mentre nei modelli ottimizzati la

differenza che la separa dalle reti neurali è molto sottile, mostrando come anche questo modello nella sua versione ottimizzata risulti molto valido. C'è da tenere in considerazione però che la rete neurale ottimizzata ha dei tempi di esecuzione molto più onerosi rispetto ad SVM.

Conclusioni

L'obiettivo di questa prima parte del progetto era sviluppare modelli di machine learning per prevedere la presenza di disturbi cardiaci basandosi su dati clinici.

Un aspetto critico emerso è lo sbilanciamento del dataset, con una predominanza maschile tra i pazienti e una frequenza maggiore di pazienti con malattia cardiaca. Questo potrebbe aver introdotto bias nei modelli, suggerendo la necessità di un dataset più ricco per ottenere modelli migliori.

L'analisi esplorativa e la PCA hanno fornito preziose informazioni sulla struttura dei dati e sulla rilevanza delle feature. La riduzione dimensionale ha mostrato che è possibile mantenere l'88% della varianza delle feature continue con quattro componenti principali. Nonostante ciò si è scelto di utilizzare il dataset originale per l'addestramento dei modelli.

Sono stati implementati e confrontati tre modelli principali: alberi di decisione, support vector machines (SVM) e reti neurali, ciascuno testato sia in una versione "naive" che ottimizzata tramite la ricerca degli iperparametri.

Alberi di Decisione: Questo modello ha registrato le performance più basse tra i tre analizzati, in particolare nella versione naive in cui ha ottenuto score delle metriche significativamente inferiori agli altri modelli. Nella versione ottimizzata ha ottenuto un significativo incremento delle performance (6% rispetto al modello naive) evidenziando una sensibilità importante alla scelta degli iperparametri. I suoi principali punti di forza includono la possibilità di operare senza standardizzazione dei dati e l'idoneità al contesto medico per la trasparenza delle decisioni. Tuttavia, presenta una maggiore tendenza all'overfitting (specialmente nella versione naive) e performance inferiori rispetto agli altri modelli.

Support Vector Machines: Le SVM hanno registrato le migliori performance sia nella versione naive che ottimizzata, con un'accuratezza di 0.875 e AUC-ROC di 0.94 nella versione ottimizzata. I punti di forza di questo modello comprendono eccellenti prestazioni con dataset di dimensioni limitate, ottima capacità discriminativa con l'AUC-ROC più elevata, robustezza e stabilità delle performance, tempi di esecuzione molto contenuti e minore sensibilità all'ottimizzazione degli iperparametri (miglioramento modesto dello 0.62%). Le principali debolezze sono la minore interpretabilità rispetto agli alberi di decisione e la necessità di standardizzazione dei dati.

Reti Neurali: Le reti neurali hanno mostrato performance competitive con SVM nella versione ottimizzata (accuratezza 0.86, AUC-ROC 0.93), ma significativo overfitting nella versione naive. I punti di forza includono la capacità di apprendere pattern complessi e relazioni non lineari, ottima capacità di generalizzazione dopo l'ottimizzazione e flessibilità nell'architettura del modello. Le debolezze principali sono la natura a "scatola nera" con limitata interpretabilità, forte tendenza all'overfitting senza un'adeguata regolarizzazione,

tempi di esecuzione significativamente più onerosi, elevata sensibilità alla scelta degli iperparametri (miglioramento del 6% con l'ottimizzazione) e la necessità di standardizzazione dei dati.

In conclusione, tutti i modelli ottimizzati hanno fornito risultati soddisfacenti, con **SVM** che si è dimostrato particolarmente efficace in termini di accuratezza e capacità discriminativa a fronte di tempo di calcolo molto brevi. L'utilizzo di tecniche di machine learning in ambito medico, come dimostrato in questo progetto, può supportare i professionisti nella diagnosi precoce, migliorando la prevenzione e l'efficacia dei trattamenti.